YNOV M1 · YDAYS 2026 - 2027

JARVIS

L'assistant vocal qui **entend, voit, parle — et pilote l'ordinateur.**



PYTHON · PYQT6 | GEMINI LIVE | CLAUDE CODE | WINDOWS · MACOS · LINUX

LE CONSTAT

Un assistant qui agit, pas seulement qui répond.

Les assistants IA vivent dans un onglet : on tape, ils répondent, **on copie-colle**.

Jarvis vit sur la machine. On lui parle, et **il le fait** — puis il montre le résultat sur son propre écran.

01
Entendre
Voix en temps réel, « Hey Jarvis », Ctrl + Espace.

02
Voir
L'écran et la webcam, sur demande.

03
Parler
5 voix, toutes les langues, un avatar qui articule.

04
Agir
Applis, fichiers, navigateur, réglages, projets.

UN FORK OPEN SOURCE

Construit sur Mark LV, poussé plus loin.

HÉRITÉ La base Mark LV

- **HUD PyQt6** et avatar holographique, rendu sans GPU
- **Gemini Live** : audio natif, faible latence
- **23 actions** auto-découvertes, plugins en un fichier
- **Mémoire** locale, annulation, confirmation réelle

APPORT YDAYS Ce que nous ajoutons

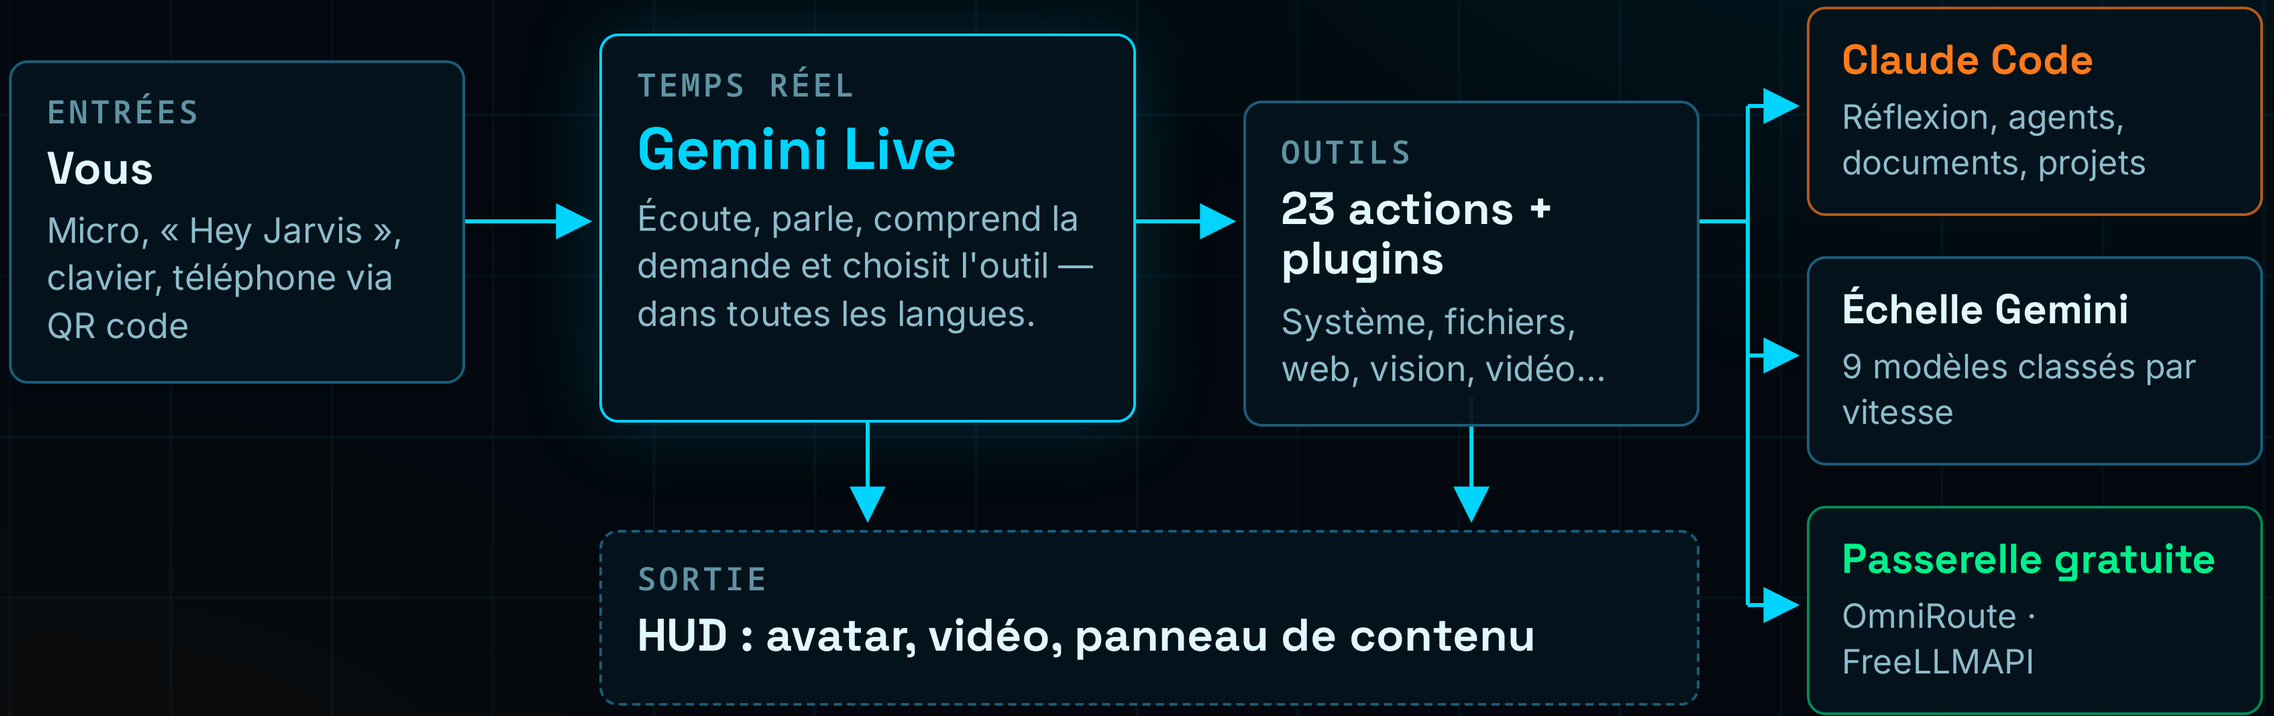
- **Passerelle gratuite** pour les petits appels
- **Compteur de tokens** par moteur et par jour
- **Projets logiciels** menés étape par étape
- Objectif : **dépenser moins de tokens**, faire plus

Mark LV — FatihMakes · licence CC BY-NC 4.0

Replica — licence MIT

COMMENT ÇA MARCHE

Une voix rapide, un cerveau qui réfléchit.



CE QU'IL SAIT FAIRE

Tout ce qu’il fait pilote l’ordinateur.

Système
Applis, volume, luminosité, Wi-Fi

Fichiers
Déplacer, renommer, ranger — et annuler

Navigateur
Ouvrir, chercher, naviguer à la voix

Vision
Lit l'écran et la webcam

Mémoire
Se souvient de vous, sans limite

Vidéo sur le HUD
YouTube, fichier ou simple description

Recherche web
Actualités, prix, comparatifs

Documents
PDF, slides, motion design

Rappels
Notifications natives de l'OS

Messages
WhatsApp, Telegram…

Télécommande
Depuis le téléphone, via QR code

Projets logiciels
De l'idée au code, étape par étape

QUAND UN MODÈLE TOMBE

Une échelle de 9 modèles.

Classés par temps de réponse **mesuré**. Avant : 16 fichiers nommaient leur propre modèle, **sans aucun timeout**.

Quota épuisé (429)	5 min
Pas de réponse (503 / 504)	30 min
Introuvable (404)	6 h

11,2 s gagnées sur chaque appel une fois le modèle en panne mis au repos.

01	gemini-3.5-flash-lite	0,56 s
02	gemini-3.1-flash-lite	0,60 s
03	gemini-flash-lite-latest	0,60 s
04	gemini-2.5-flash	0,67 s
05	gemini-2.5-flash-lite	0,74 s
06	gemini-3.5-flash	1,13 s
07	gemini-3-flash-preview	504 après 14,7 s
08	gemini-3.6-flash	504 après 12,0 s
09	gemini-flash-latest	503 indisponible

MOINS DE TOKENS CLAUDE

Une passerelle gratuite en premier.

Classer une phrase, trouver un bouton à l'écran : chaque petit appel consommait le **quota Claude** dont les documents et les projets ont besoin.

Appels rapides les plus fréquents	Passerelle gratuite → Claude → Échelle Gemini
Appels réfléchis raisonnement, code	Claude → Échelle Gemini → Passerelle gratuite
Recherche ancrée sources web citées	Gemini seul

OmniRoute ou FreeLLMAPI regroupent les **offres gratuites** de dizaines de fournisseurs (Groq, Cerebras, Mistral, OpenRouter…) derrière une seule API compatible OpenAI. Une passerelle en panne est mise au repos 2 à 30 min.

MESURER AVANT D'OPTIMISER

Une économie devient un chiffre.

- **Chaque moteur** déclare les tokens qu'il a consommés
- **Par jour**, gardé 14 jours, affiché dans les réglages
- **Écriture atomique** : un plantage ne corrompt rien
- **Ne lève jamais d'erreur** : compter ne casse pas une réponse

CLAUDE · CLAUDE TÂCHES · PASSERELLE · GEMINI

config/usage.json

```
{
  "2026-10-21": {
    "claude": {
      "calls": …, "in": …,
      "out": …, "cached": …
    },
    "claude-agent": { … },
    "gateway":      { … },
    "gemini":       { … }
  }
}
```

PROJETS LOGICIELS

De l'idée au code, une étape à la fois.

« Crée un projet : une appli de budget pour étudiants. »

CLONE D'UNE APPLI EXISTANTE

recon — architect — design — build — backend — test — diff — entrepreneur — brand — launch

VOTRE PROPRE IDÉE

spec — architect — design — build — backend — test — diff

Opus — étapes lourdes Sonnet — le reste Étape ajoutée par nous

Une étape à la fois
Vous décidez quand l'heure d'Opus suivante en vaut la peine.

Session neuve
On transmet quelques Ko de notes, pas tout l'historique.

Le bon modèle
Opus pour bâtir, Sonnet pour chercher, tester, noter.

Skills locales
Rangées dans le projet : les autres tâches ne les paient pas.

UN ASSISTANT QUI AGIT DOIT ÊTRE SÛR

Il agit vite. Rien d’irréversible sans vous.



Une vraie confirmation

Arrêt, redémarrage, Wi-Fi : une bannière s'affiche, l'action ne part que si **vous** cliquez. Le modèle ne peut pas la valider lui-même.



Tout s’annule

Fichiers déplacés, renommés, créés, écrits — et réglages modifiés. « Annule », dans n'importe quelle langue.



Vos données restent chez vous

Pas de serveur, pas de télémétrie, pas de compte. Mémoire, clés et compteurs en local, exclus de git.

MESURÉ, PAS SUPPOSÉ

Chaque optimisation a son chiffre.

11,2 s

gagnées sur chaque appel après la panne d'un modèle

≈ 1 000

tokens de moins à chaque session : 16 827 → 12 907 caractères d'outils

41 → 8

périphériques audio : la liste que l'OS montre vraiment

211 → 39 ms

pour charger les plugins au démarrage

971

caractères de prompt pour une mémoire de 62 faits

≈ 28 700

lignes de Python, sur Windows, macOS et Linux

EN DIRECT

Il suffit de lui parler.

> « Hey Jarvis, mets la bande-annonce de Dune. »	La vidéo prend la place de l'avatar, son coupé.
> « Range mon bureau. » … « Annule. »	Chaque fichier retourne à sa place.
> « Qu’est-ce que tu vois sur mon écran ? »	Capture, lecture, réponse à voix haute.
> « Crée un projet : une appli de budget. »	Un dossier, un brief, la première étape.
> « Éteins l’ordinateur. »	Une bannière : rien ne part sans votre clic.



Merci. Des questions ?

Jarvis — l'assistant qui entend, voit, parle et agit.

ET ENSUITE

- Interrompre à la voix
- Historique des conversations
- Contrôle via Telegram
- Accès complet aux fichiers
- Obsidian

Base : Mark LV par FatihMakes (CC BY-NC 4.0) · Méthode projets : Replica (MIT)